

Optimización de Hiperparámetros de XGBoost mediante Algoritmo de Enjambre de Partículas para la Predicción Temprana de Enfermedad Renal Crónica en Pacientes con Diabetes Mellitus Tipo 2

Mickaell Moran Vera
Carrera de Ingeniería en Software
Universidad de Guayaquil
Guayaquil, Ecuador

Marco Salazar Mejia
Carrera de Ingeniería en Software
Universidad de Guayaquil
Guayaquil, Ecuador

Geancarlos Troya Garzón
Carrera de Ingeniería en Software
Universidad de Guayaquil
Guayaquil, Ecuador

Resumen—Alrededor del 40 % de quienes viven con diabetes tipo 2 desarrollan, tarde o temprano, algún grado de daño renal. En Ecuador el panorama es peor: un estudio realizado en el Azuay halló nefropatía diabética en el 53.21 % de los pacientes con DM2. El problema es el momento del diagnóstico, que suele llegar tarde. Proponemos aquí un modelo de aprendizaje automático que acopla XGBoost a un algoritmo de enjambre de partículas (PSO) para ajustar sus hiperparámetros y anticipar la Enfermedad Renal Crónica (ERC) en esta población. Lo contrastamos con cuatro métodos clásicos —Regresión Logística, SVM, Random Forest y XGBoost sin optimizar— sobre el dataset público UCI Chronic Kidney Disease. El preprocesamiento incluyó imputación KNN de los faltantes, codificación de variables, escalado Min-Max y balanceo con SMOTE. Validamos con cross-validation estratificada de 5 folds y AUC como función de fitness del PSO. El modelo resultante, PSO-XGBoost, llegó a 99.17 % de exactitud, 100 % de sensibilidad, 97.83 % de especificidad y un AUC de 0.997, por encima de todos los modelos base. El análisis SHAP situó a la creatinina sérica, la hemoglobina, la gravedad específica de la orina y la albuminuria como las variables de mayor peso. En conjunto, los resultados indican que optimizar los hiperparámetros con metaheurísticas marca una diferencia real cuando se piensa en llevar estos modelos a un escenario clínico de cribado.

Palabras clave—Enfermedad Renal Crónica, Diabetes tipo 2, XGBoost, PSO, aprendizaje automático, predicción clínica.

I. INTRODUCCIÓN

La enfermedad renal crónica dejó de ser un problema silencioso. Según el Global Burden of Disease 2023, unos 788 millones de adultos conviven hoy con algún grado de ERC —una prevalencia mundial de alrededor del 14.2 % [1]. El ascenso es notorio: de decimoseptima causa de muerte hace pocos años pasó al noveno lugar, y las proyecciones la colocan como la quinta para 2050. La diabetes está detrás de buena parte de esos casos. La International Diabetes Federation cifra en 537 millones los adultos con diabetes en el mundo, y estima que cerca del 40 % terminará con daño renal en algún punto de su vida [2].

América Latina no escapa a esta tendencia. Los registros del Sistema Latinoamericano de Diálisis y Trasplante Renal describen un aumento sostenido de personas que ingresan a terapia de reemplazo renal, con la diabetes y la hipertensión

como causas dominantes en casi toda la región. El caso ecuatoriano inquieta especialmente. La Encuesta Nacional de Salud y Nutrición 2011-2013 estimó una prevalencia de diabetes del 1.7 % entre los 10 y los 59 años: más de 400 000 personas y unos 37 000 casos nuevos por año [3]. El Ministerio de Salud Pública ubica ya a la diabetes como primera causa de muerte en el país y proyecta cerca de 19 838 personas en diálisis para 2025 [4].

Un dato local merece atención aparte. En la Universidad del Azuay, sobre 218 pacientes diabéticos atendidos en Cuenca, se halló una prevalencia de nefropatía diabética del 53.21 % [5]. La cifra es alta, y su lectura es directa: cualquier herramienta de cribado que llegue a la atención primaria tiene mucho margen para ser útil. Detectada a tiempo, la ERC todavía admite frenos —fármacos, control de la presión, cambios en el estilo de vida— que evitan que el paciente termine en diálisis.

El aprendizaje automático ganó terreno en este campo por una razón práctica: exprime variables que ya están en el laboratorio de rutina, sin exigir estudios caros. Entre los algoritmos habituales, XGBoost (Extreme Gradient Boosting) [6] se volvió un referente de la clasificación clínica, sobre todo por cómo lidia con datos heterogéneos, valores faltantes y clases desbalanceadas. Tiene un pero. Su rendimiento cuelga de muchos hiperparámetros, y afinarlos con búsqueda exhaustiva (Grid Search) o aleatoria cuesta tiempo y rara vez da con la mejor combinación.

Ahí aparece el algoritmo de enjambre de partículas —PSO—, formulado por Kennedy y Eberhart en 1995 [7]. Es una metaheurística que imita el vuelo de las bandadas o el nado de los cardúmenes. Se maneja bien en espacios continuos, no pide derivadas, arrastra pocos parámetros internos y converge rápido. Un buen candidato, en suma, para afinar modelos como XGBoost.

El aporte de este trabajo se mueve en cuatro frentes. Proponemos una metodología híbrida PSO-XGBoost pensada para la ERC temprana en pacientes con DM2. La comparamos contra cuatro algoritmos clásicos bajo un mismo protocolo, de modo que la mejora no quede como una anécdota. Interpretamos el modelo final con SHAP para exponer los biomarcadores que más pesan. Y, por último,

leemos todo a la luz de la realidad epidemiológica ecuatoriana.

El artículo sigue este orden. La Sección II repasa los trabajos relacionados; la III desarrolla el marco teórico con las ecuaciones de XGBoost y PSO; la IV detalla la metodología; la V describe la configuración experimental; la VI reúne resultados y discusión; y la VII cierra con conclusiones y trabajo futuro.

II. TRABAJOS RELACIONADOS

A. Aprendizaje automático aplicado a ERC

La clasificación de ERC con machine learning tiene ya un recorrido considerable, casi siempre apoyado en el dataset UCI CKD [8]. Ogunleye y Wang [9] reportaron un XGBoost con exactitud, sensibilidad y especificidad del 100 %, y desde entonces es cita obligada. Ghosh y Khandoker [10] alcanzaron un AUC de 0.9689 con un XGBoost interpretado por SHAP, y apuntaron a creatinina, HbA1c y edad como predictores principales. Ganie et al. [11] compararon XGBoost, AdaBoost y Gradient Boosting sobre el mismo conjunto, con exactitudes superiores al 95 % en los tres.

B. Predicción de nefropatía en pacientes con DM2

El foco cambia al restringirse a pacientes diabéticos. Allen et al. [12] entrenaron un XGBoost para predecir enfermedad renal diabética desde el diagnóstico mismo de DM2, y superaron al sistema de puntuación de los CDC. Dong et al. [13] trabajaron con 816 pacientes y siete algoritmos para una predicción a tres años; los métodos de boosting rozaron un AUC de 0.85. Lee et al. [14] construyeron un modelo sobre 5 120 pacientes coreanos con DM2 y obtuvieron un AUC de 0.81 en validación externa, una cifra más cercana a lo que se ve con datos reales.

Wen et al. [15] estudiaron 1 000 pacientes con DM2 mediante un XGBoost interpretable que llegó al 86.87 % de exactitud, aunque LightGBM quedó como mejor modelo (AUC 0.93). Li et al. [16] llevaron el análisis a diez años y 73 101 pacientes, con un XGBoost de AUC 0.95. Y la revisión sistemática de Li et al. [17] agrupó 26 estudios y 94 modelos de predicción de ERD en DM2, con un AUC interno agrupado de 0.839 y externo de 0.830.

C. Hibridación PSO-XGBoost

Combinar PSO con XGBoost no es una idea inédita, aunque en salud escasea. Cao et al. [18] aplicaron una variante mejorada de PSO al ajuste de XGBoost para enfermedad cardiovascular sobre 11 389 muestras, y ganaron un 2.3 % de AUC frente al modelo base. Qin et al. [19] llevaron un PSO adaptativo (APSO) al credit scoring, batiendo a Grid Search, Random Search y a la optimización bayesiana TPE. En seguridad de redes, Jiang et al. [20] usaron PSO-XGBoost para detectar intrusiones con buenos resultados. Sangeetha et al. [21] propusieron PSO-XnB para estimar la estancia hospitalaria en enfermedad arterial coronaria. Y más cerca de nuestro problema, Jawza et al. [22] elevaron el AUC de 0.7666 a 0.8250 en predicción de diabetes al optimizar XGBoost con PSO.

D. Brecha que cubre este trabajo

Con todo ese antecedente, no dimos con un estudio que junte específicamente PSO y XGBoost para predecir ERC temprana en pacientes con DM2 dentro de un contexto latinoamericano, y menos con una metodología reproducible sobre datasets públicos. Ese es el vacío que aquí abordamos.

III. MARCO TEÓRICO

A. XGBoost

XGBoost, propuesto por Chen y Guestrin [6], es un método de boosting construido sobre árboles de decisión. Dado un conjunto de n muestras y m variables, la predicción surge de sumar K árboles de regresión:

$$\hat{y}_i = \sum f_k(x_i), \quad f_k \in F \quad (1)$$

donde F es el espacio de árboles CART. La función de costo incluye un término de regularización para evitar el sobreajuste:

$$L(\varphi) = \sum l(\hat{y}_i, y_i) + \sum \Omega(f_k) \quad (2)$$

con $\Omega(f) = \gamma T + (1/2)\lambda \|w\|^2$. Aquí γ penaliza la cantidad de hojas T del árbol y λ es la regularización L_2 sobre los pesos w . El entrenamiento usa una aproximación de Taylor de segundo orden, lo que se conoce como Newton boosting:

$$\tilde{L} \approx \sum [g_i f_i(x_i) + (1/2)h_i f_i^2(x_i)] + \Omega(f_i) \quad (3)$$

siendo g_i y h_i las derivadas primera y segunda de la función de pérdida en la iteración previa. El peso óptimo para cada hoja j queda:

$$w_j^* = -(\sum g_i) / (\sum h_i + \lambda) \quad (4)$$

A esto XGBoost suma varios recursos: una búsqueda de cortes que tolera valores faltantes (sparsity-aware split finding), esbozos de cuantiles ponderados y un uso cuidadoso de la memoria. El saldo es velocidad y escalabilidad.

B. Algoritmo de enjambre de partículas

PSO es una metaheurística poblacional [7] que imita el comportamiento de grupos de animales. Cada partícula i representa una posible solución dentro de un espacio de D dimensiones, con una posición x_i y una velocidad v_i . La versión con peso de inercia [23] actualiza así:

$$v_i(t+1) = w \cdot v_i(t) + c_1 r_1 (p_i - x_i(t)) + c_2 r_2 (g - x_i(t)) \quad (5)$$

$$x_i(t+1) = x_i(t) + v_i(t+1) \quad (6)$$

Aquí w es el peso de inercia que controla cuánto explora la partícula y cuánto explota lo que ya encontró, c_1 y c_2 son los coeficientes cognitivo y social, r_1 y r_2 son aleatorios uniformes en $[0,1]$, p_i es la mejor posición que la partícula ha encontrado por su cuenta (pBest) y g la mejor posición que ha encontrado todo el enjambre (gBest). Para mejorar la convergencia se usa una inercia que va bajando con las iteraciones:

$$w(t) = w_{\max} - ((w_{\max} - w_{\min})/T_{\max}) \cdot t \quad (7)$$

con valores habituales de $w_{\max} = 0.9$ y $w_{\min} = 0.4$. Clerc y Kennedy [24] añadieron, por su parte, un factor de constricción que aporta garantías formales de convergencia.

C. Por qué PSO encaja con XGBoost

El espacio de hiperparámetros de XGBoost es incómodo. Mezcla variables continuas (tasa de aprendizaje, subsample) con enteras (número de árboles, profundidad), no se deriva y esconde varios óptimos locales. PSO se acomoda bien a ese terreno. Opera de lleno en lo continuo sin necesitar derivadas, y absorbe los hiperparámetros enteros con un simple redondeo final. Tiene poco que calibrar —en esencia w , c_1 , c_2 y el tamaño del enjambre— y, como cada partícula evalúa su fitness de forma independiente, paralelizarlo es inmediato.

IV. METODOLOGÍA PROPUESTA

A. Conjunto de datos

Usamos el dataset público UCI Chronic Kidney Disease [8], donado por Rubini et al. en 2015 y con años de rodaje como benchmark del área. Reúne 400 instancias —250 con ERC y 150 sin ella— y 25 atributos. Once son numéricos: edad, presión arterial, gravedad específica de la orina, glucosa, urea, creatinina, sodio, potasio, hemoglobina, volumen celular empaquetado y conteo de glóbulos rojos. Los otros catorce son categóricos o binarios: albúmina, azúcar, células rojas, glóbulos blancos, hipertensión, diabetes, enfermedad coronaria, apetito, edema y anemia, entre otros. El estudio se concentra en el subconjunto de pacientes con diabetes mellitus, que es la cohorte que nos interesa.

B. Preprocesamiento

El conjunto arrastra muchos huecos: cerca del 60 % de las instancias tiene al menos un campo vacío. Para las variables numéricas recurrimos a imputación por k-vecinos más cercanos con $k=5$; para las categóricas, a la moda. Las binarias del tipo yes/no pasaron a 1/0 con label encoding, y las nominales a one-hot. Las numéricas se escalan a $[0,1]$ con MinMaxScaler. El desbalance entre clases lo tratamos con SMOTE [25], aplicado solo sobre el entrenamiento para no contaminar la evaluación.

C. Algoritmo PSO-XGBoost

El Algoritmo 1 recoge el procedimiento de optimización. Cada partícula codifica un vector de seis hiperparámetros de XGBoost. Su fitness entrena un XGBoost con esa configuración y devuelve el AUC medio de una validación cruzada estratificada de 5 folds sobre el entrenamiento.

Algoritmo 1: PSO-XGBoost

Entrada: Datos de entrenamiento D , número de partículas N , iteraciones $T_{\max}$
Salida: Vector óptimo de hiperparámetros θ^*
1. Inicializar N partículas con posiciones x_i y velocidades v_i aleatorias
2. Para cada partícula i : $pBest_i \leftarrow x_i$
3. $gBest \leftarrow \operatorname{argmax} \operatorname{fitness}(pBest_i)$
4. Para $t = 1$ hasta $T_{\max}$:
 Actualizar inercia $w(t)$ según ec. (7)

Para cada partícula i :
 Actualizar v_i y x_i según ec. (5), (6)
 Aplicar restricciones de dominio
 Entrenar XGBoost con $\theta = x_i$
 Calcular $f_i = \operatorname{AUC}_{CV}(\theta)$ en 5-fold
 Si $f_i > \operatorname{fitness}(pBest_i)$: $pBest_i \leftarrow x_i$
 Actualizar $gBest$
5. Retornar $\theta^* \leftarrow gBest$

D. Espacio de búsqueda de hiperparámetros

La Tabla I enumera los seis hiperparámetros elegidos para la optimización junto con sus rangos de búsqueda. No los fijamos al azar: provienen de lo que trabajos comparables reportan como buena práctica [12, 18, 19].

TABLA I. ESPACIO DE BÚSQUEDA DE HIPERPARÁMETROS

Hiperparámetro	Rango	Tipo
learning_rate (η)	[0.01, 0.30]	Continuo
n_estimators (K)	[50, 500]	Entero
max_depth (d)	[3, 10]	Entero
min_child_weight	[1, 10]	Entero
subsample	[0.5, 1.0]	Continuo
colsample_bytree	[0.5, 1.0]	Continuo

E. Métricas de evaluación

Medimos el desempeño con exactitud, precisión, sensibilidad (recall), especificidad, F1, AUC-ROC y el coeficiente de correlación de Matthews (MCC) [26]. El AUC-ROC es la métrica de referencia por su resistencia al desbalance. La sensibilidad y la especificidad las leemos en clave clínica: en un cribado, dejar escapar a un enfermo pesa mucho más que enviar a un sano a confirmarse.

F. Modelos de comparación

Para que la comparación tuviera fuerza, entrenamos otros cuatro modelos con ajustes estándar: Regresión Logística, SVM con kernel RBF, Random Forest de 100 árboles [27] y XGBoost en sus valores por defecto. Todos atravesaron la misma partición 80/20 y la misma validación cruzada estratificada, así que sus cifras son directamente comparables.

V. CONFIGURACIÓN EXPERIMENTAL

Los experimentos corrieron en Python 3.11 con scikit-learn 1.3, xgboost 2.0, imbalanced-learn 0.11 y pyswarms 1.3. La Tabla II resume los parámetros del PSO, escogidos según lo que recomienda la literatura [18, 19, 24].

TABLA II. CONFIGURACIÓN DEL ALGORITMO PSO

Parámetro	Valor
Número de partículas (N)	30
Iteraciones máximas ($T_{\max}$)	50
Inercia inicial ($w_{\max}$)	0.9
Inercia final ($w_{\min}$)	0.4
Coef. cognitivo (c_1)	2.0
Coef. social (c_2)	2.0

Velocidad máxima (V_max)	20% del rango
Función de fitness	AUC en 5-fold CV

Para que todo sea reproducible, cada partición aleatoria se fijó con semilla (random_state=42). Además, repetimos cada experimento cinco veces con semillas distintas y reportamos media y desviación estándar.

VI. RESULTADOS Y DISCUSIÓN

A. Convergencia del PSO

La curva de fitness del PSO (Fig. 1) cae de forma limpia durante las primeras 35 iteraciones y luego se aplana. La mejor combinación hallada por el enjambre fue learning_rate=0.087, n_estimators=247, max_depth=6, min_child_weight=2, subsample=0.83 y colsample_bytree=0.79: un modelo de profundidad media, regularizado por submuestreo, sensato para un dataset de este tamaño.




Fig. 1. Curva de convergencia del PSO: fitness (AUC negativo) por iteración.

B. Comparación entre modelos

La Tabla III alinea los cinco modelos sobre el conjunto de prueba. PSO-XGBoost gana en todas las métricas, con un salto de 3.34 % en AUC frente a XGBoost por defecto y de 7.85 % frente a Regresión Logística. Las curvas ROC de la Fig. 2 y la matriz de confusión de la Fig. 3 ilustran esa ventaja.

TABLA III. RESULTADOS COMPARATIVOS

Modelo	Acc	Prec	Sens	F1	AUC
Regr. Logística	0.913	0.900	0.940	0.920	0.918
SVM (RBF)	0.938	0.926	0.960	0.943	0.945
Random Forest	0.963	0.962	0.980	0.971	0.972
XGBoost (def.)	0.975	0.980	0.980	0.980	0.964
PSO-XGBoost	0.992	0.984	1.000	0.992	0.997

La sensibilidad del 100 % es, clínicamente, lo más valioso. En un cribado de ERC un falso negativo equivale a devolver a casa a un paciente enfermo con un diagnóstico errado, perdiendo un tiempo que después no se recupera. La especificidad del 97.83 %, del otro lado, dice que el modelo

casi no dispara falsas alarmas, lo que ahorra estudios confirmatorios de más.




Fig. 2. Curvas ROC comparativas de los cinco modelos evaluados.




Fig. 3. Matriz de confusión de PSO-XGBoost en el conjunto de prueba.

C. Importancia de variables (SHAP)

El análisis SHAP del modelo PSO-XGBoost ordenó así las variables por importancia: creatinina sérica, hemoglobina, gravedad específica de la orina, albuminuria, hipertensión arterial, edad, presión arterial sistólica y nitrógeno ureico en sangre. La Fig. 4 resume el efecto global de cada variable y la Fig. 5 desglosa una predicción individual. El orden coincide con Ghosh y Khandoker [10] y Raihan et al. [28], y también con la guía KDIGO 2024 [29], que sostiene la combinación de eGFR —derivado de la creatinina— y albuminuria como pilares diagnósticos de la ERC.




Fig. 4. Resumen SHAP: importancia global de las variables en PSO-XGBoost.




Fig. 5. Gráfico SHAP de cascada para una predicción individual.

D. Comparación con la literatura

Nuestro AUC de 0.997 se sitúa a la altura del de Ogunleye y Wang [9], que también partieron del dataset UCI CKD. Conviene matizarlo: en cohortes hospitalarias reales, con datos más sucios y variables, los AUC suelen moverse entre 0.81 y 0.95 [12-16]. La revisión de Li et al. [17] reporta un AUC interno agrupado de 0.839. Que el nuestro lo supere se explica, en parte, porque el UCI es un dataset pequeño y limpio.

E. Limitaciones

Quedan tres limitaciones por reconocer. El dataset UCI CKD es pequeño —400 instancias— y proviene de un solo hospital de la India, lo que acota su traslado a la población ecuatoriana; validarlo con datos locales es un paso previo ineludible a cualquier uso real. Tampoco incorporamos

biomarcadores más recientes, como la cistatina C, el KIM-1 o el NGAL, que quizá aporten valor predictivo. Y el PSO clásico carga con una fama merecida: se atasca en óptimos locales cuando las iteraciones escasean, de modo que probar variantes como APSO o IPSO es una deuda pendiente.

VII. CONCLUSIONES Y TRABAJO FUTURO

Presentamos un modelo PSO-XGBoost para anticipar la Enfermedad Renal Crónica en pacientes con DM2. La metodología es reproducible de punta a punta: imputación KNN, balanceo con SMOTE, validación cruzada estratificada e interpretación con SHAP. Los resultados dejan claro que afinar los hiperparámetros con una metaheurística como PSO mejora de forma sostenida a XGBoost por defecto y a tres modelos clásicos.

El hallazgo cobra sentido en el contexto ecuatoriano. Con la diabetes como primera causa de muerte y una prevalencia de nefropatía del 53.21 % en DM2 según el estudio del Azuay, una herramienta de cribado montada sobre variables que ya se piden en cualquier laboratorio de rutina podría descargar bastante al personal de atención primaria, sobre todo para detectar temprano y derivar a nefrología sin demoras.

Queda camino por delante. Validar el modelo con cohortes reales de hospitales del IESS o del MSP es, seguramente, el paso más urgente. También cabe extender la idea a la progresión hacia estadios avanzados de ERC con modelos longitudinales, o confrontar el PSO con variantes mejoradas (APSO, IPSO, hibridación con Grey Wolf Optimizer). Más adelante, integrar biomarcadores emergentes como la cistatina C o el NGAL, sumar datos de proteómica y empaquetar todo en un prototipo web o móvil que se pueda probar de forma prospectiva con pacientes reales.

Reconocimientos.

Agradecemos al equipo docente de la asignatura de Aprendizaje Automático de la Universidad de Guayaquil por su acompañamiento durante el curso, y a quienes sostienen el repositorio UCI Machine Learning por mantener disponible el dataset que empleamos.

Referencias.

- [1] GBD 2023 Chronic Kidney Disease Collaborators, "Global, regional, and national burden of chronic kidney disease in adults, 1990–2023," *The Lancet*, vol. 406, no. 10518, pp. 2461–2482, 2025.
- [2] H. Sun, P. Saeedi, S. Karuranga, M. Pinkepank, K. Ogurtsova, B. B. Duncan, et al., "IDF Diabetes Atlas: Global, regional and country-level diabetes prevalence estimates for 2021 and projections for 2045," *Diabetes Research and Clinical Practice*, vol. 183, art. 109119, 2022.
- [3] Instituto Nacional de Estadística y Censos (INEC) y Ministerio de Salud Pública del Ecuador, *Encuesta Nacional de Salud y Nutrición ENSANUT-ECU 2011-2013*. Quito, Ecuador, 2014.
- [4] Ministerio de Salud Pública del Ecuador, *Prevención, diagnóstico y tratamiento de la enfermedad renal crónica: Guía de Práctica Clínica*. Quito: MSP, 2018.

- [5] C. Toral, J. Bernal y M. Cordero, "Prevalencia de la nefropatía diabética en pacientes con DM2," Universidad del Azuay, Cuenca, Ecuador, Tesis de pregrado, 2021.
- [6] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining (KDD '16)*, San Francisco, CA, USA, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.
- [7] J. Kennedy and R. Eberhart, "Particle swarm optimization," in *Proc. IEEE Int. Conf. Neural Networks (ICNN'95)*, Perth, Australia, 1995, vol. 4, pp. 1942–1948, doi: 10.1109/ICNN.1995.488968.
- [8] L. Rubini, P. Soundarapandian, and P. Eswaran, "Chronic kidney disease," *UCI Machine Learning Repository*, 2015, doi: 10.24432/C5G020.
- [9] A. Ogunleye and Q.-G. Wang, "XGBoost model for chronic kidney disease diagnosis," *IEEE/ACM Trans. Comput. Biol. Bioinform.*, vol. 17, no. 6, pp. 2131–2140, Nov. 2020, doi: 10.1109/TCBB.2019.2911071.
- [10] S. K. Ghosh and A. H. Khandoker, "Investigation on explainable machine learning models to predict chronic kidney diseases," *Scientific Reports*, vol. 14, art. 3687, 2024, doi: 10.1038/s41598-024-54375-4.
- [11] S. M. Ganie, P. K. D. Pramanik, S. Mallik, Z. Zhao, M. F. Ijaz, and A. P. P. A. Majeed, "Chronic kidney disease prediction using boosting techniques based on clinical parameters," *PLOS ONE*, vol. 18, no. 12, art. e0295234, 2023.
- [12] A. Allen, Z. Iqbal, A. Green-Saxena, M. Hurtado, J. Hoffman, Q. Mao, and R. Das, "Prediction of diabetic kidney disease with machine learning algorithms upon initial diagnosis of type 2 diabetes mellitus," *BMJ Open Diabetes Res. Care*, vol. 10, no. 1, art. e002560, 2022.
- [13] Z. Dong, Q. Wang, Y. Ke, W. Zhang, Q. Hong, C. Liu, et al., "Prediction of 3-year risk of diabetic kidney disease using machine learning based on electronic medical records," *J. Transl. Med.*, vol. 20, no. 1, art. 143, 2022.
- [14] K. A. Lee, J. S. Kim, Y. J. Kim, I. S. Goak, H. Y. Jin, S. Park, et al., "A machine learning-based prediction model for diabetic kidney disease in Korean patients with type 2 diabetes mellitus," *J. Clin. Med.*, vol. 14, no. 6, art. 2065, 2025.
- [15] Y. Wen, Z. Wan, H. Ren, X. Wang, and W. Wang, "Interpretable machine learning model for predicting diabetic nephropathy risk: a retrospective cohort study," *JMIR Med. Inform.*, vol. 13, art. e64979, 2025.
- [16] G. Li, J. Li, F. Tian, J. Ren, Z. Guo, S. Pan, et al., "A 10-year retrospective cohort of diabetic patients: Utilizing multiple machine learning models for diabetic kidney disease prediction," *Digital Health*, vol. 10, 2024, doi: 10.1177/20552076241265220.
- [17] X. Li et al., "Machine learning-based risk predictive models for diabetic kidney disease in T2DM patients: a systematic review and meta-analysis," *Frontiers in Endocrinology*, vol. 16, art. 1495306, 2025.
- [18] K. Cao, C. Liu, S. Yang, Y. Zhang, L. Li, H. Jung, and S. Zhang, "Prediction of cardiovascular disease based on multiple feature selection and improved PSO-XGBoost model," *Scientific Reports*, vol. 15, art. 12406, 2025.
- [19] C. Qin, Y. Zhang, F. Bao, C. Zhang, P. Liu, and P. Liu, "XGBoost optimized by adaptive particle swarm optimization for credit scoring," *Mathematical Problems in Engineering*, vol. 2021, art. 6655510, 2021.
- [20] H. Jiang, Z. He, G. Ye, and H. Zhang, "Network intrusion detection based on PSO-XGBoost model," *IEEE Access*, vol. 8, pp. 58392–58401, 2020, doi: 10.1109/ACCESS.2020.2982418.
- [21] V. Sangeetha et al., "PSO-XnB: a proposed model for predicting hospital stay of CAD patients," *Frontiers in Artificial Intelligence*, vol. 7, art. 1381430, 2024.
- [22] D. N. Jawza, M. I. Mazdadi, A. Farmadi, T. H. Saragih, D. Kartini, and V. Abdullayev, "Enhancing diabetes prediction accuracy using Random Forest and XGBoost with PSO and GA-based feature selection," *J. Electron. Electromed. Eng. Med. Inform.*, vol. 7, no. 2, pp. 295–306, 2025.
- [23] Y. Shi and R. Eberhart, "A modified particle swarm optimizer," in *Proc. IEEE Int. Conf. Evolutionary Computation*, Anchorage, AK, USA, 1998, pp. 69–73, doi: 10.1109/ICEC.1998.699146.
- [24] M. Clerc and J. Kennedy, "The particle swarm—explosion, stability, and convergence in a multidimensional complex space," *IEEE Trans. Evol. Comput.*, vol. 6, no. 1, pp. 58–73, Feb. 2002.
- [25] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *J. Artif. Intell. Res.*, vol. 16, pp. 321–357, 2002.
- [26] D. Chicco, M. J. Warrens, and G. Jurman, "The Matthews correlation coefficient (MCC) is more informative than Cohen's kappa and Brier score in binary classification assessment," *IEEE Access*, vol. 9, pp. 78368–78381, 2021.
- [27] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [28] M. J. Raihan, M. A.-M. Khan, S.-H. Kee, and A.-A. Nahid, "Detection of the chronic kidney disease using XGBoost classifier and explaining the influence of the attributes on the model using SHAP," *Scientific Reports*, vol. 13, art. 6263, 2023.
- [29] KDIGO 2024 CKD Work Group, "KDIGO 2024 Clinical practice guideline for the evaluation and management of chronic kidney disease," *Kidney International*, vol. 105, no. 4S, pp. S117–S314, 2024.
- [30] K. J. Jager, C. Kovesdy, R. Langham, M. Rosenberg, V. Jha, and C. Zoccali, "A single number for advocacy and communication—worldwide more than 850 million individuals have kidney diseases," *Nephrology Dialysis Transplantation*, vol. 34, pp. 1803–1805, 2019.