

Optimización de Hiperparámetros de XGBoost mediante Algoritmo de Enjambre de Partículas para la Predicción Temprana de Enfermedad Renal Crónica en Pacientes con Diabetes Mellitus Tipo 2

Hyperparameter Optimization of XGBoost through Particle Swarm Optimization for the Early Prediction of Chronic Kidney Disease in Patients with Type 2 Diabetes Mellitus

Mickaell Moran Vera

Estudiante de Ingeniería en Software
Facultad de Ciencias Matemáticas y
Físicas

Universidad de Guayaquil
Guayaquil, Ecuador

mickael.moranvera@ug.edu.ec

Marco Salazar Mejia

Estudiante de Ingeniería en Software
Facultad de Ciencias Matemáticas y
Físicas

Universidad de Guayaquil
Guayaquil, Ecuador

marco.salazarmeja@ug.edu.ec

Geancarlos Troya Garzón

Estudiante de Ingeniería en Software
Facultad de Ciencias Matemáticas y
Físicas

Universidad de Guayaquil
Guayaquil, Ecuador

gean.troyagar@ug.edu.ec

Resumen

Introducción: La Enfermedad Renal Crónica (ERC) figura entre las complicaciones más frecuentes y serias de la Diabetes Mellitus tipo 2 (DM2). En Ecuador, un estudio local sitúa la prevalencia de nefropatía diabética en el 53.21 % de los pacientes con DM2, cifra que justifica el interés por herramientas de cribado temprano apoyadas en variables clínicas de rutina.

Objetivo: Diseñar y evaluar un modelo predictivo basado en XGBoost, con sus hiperparámetros optimizados mediante el algoritmo de Enjambre de Partículas (PSO), orientado a la detección temprana de ERC en pacientes con DM2.

Materiales y métodos: Se trabajó con el conjunto público UCI Chronic Kidney Disease (400 instancias, 25 atributos). Los faltantes se imputaron por KNN ($k=5$), las categóricas se codificaron y las numéricas se escalaron con MinMaxScaler. El desbalance se corrigió con SMOTE, aplicado únicamente al entrenamiento. El PSO se configuró con 30 partículas, 50 iteraciones e inercia decreciente, y su fitness maximizó el AUC en validación cruzada estratificada de 5 folds. Como referencia se entrenaron Regresión Logística, SVM (RBF), Random Forest y XGBoost con valores por defecto.

Resultados: PSO-XGBoost alcanzó una exactitud del 99.17 %, precisión del 98.4 %, sensibilidad del 100 %, especificidad del 97.83 %, F1 de 0.992 y AUC-ROC de 0.997, por delante de los cuatro modelos base. El análisis SHAP señaló como variables más influyentes la creatinina sérica, la hemoglobina, la gravedad específica de la orina y la albuminuria.

Conclusiones: El ajuste metaheurístico de hiperparámetros con PSO mejora de manera consistente a XGBoost en la predicción temprana de ERC en pacientes con DM2, y lo hace apoyándose en biomarcadores coherentes con la guía KDIGO 2024. En conjunto, los resultados respaldan la viabilidad de un sistema de cribado adaptable al contexto ecuatoriano.

Palabras clave (DeCS/MeSH): Insuficiencia Renal Crónica; Diabetes Mellitus Tipo 2; Aprendizaje Automático; Algoritmos; Nefropatías Diabéticas.

La enfermedad renal crónica dejó de ser un problema silencioso. Según el Global Burden of Disease 2023, unos 788 millones de adultos conviven hoy con algún grado de ERC —una prevalencia mundial de alrededor del 14.2 % [1]. El ascenso es notorio: de decimoseptima causa de muerte hace pocos años pasó al noveno lugar, y las proyecciones la colocan como la quinta para 2050. La diabetes está detrás de buena parte de esos casos. La International Diabetes Federation cifra en 537 millones los adultos con diabetes en el mundo, y estima que cerca del 40 % terminará con daño renal en algún punto de su vida [2].

América Latina no escapa a esta tendencia. Los registros del Sistema Latinoamericano de Diálisis y Trasplante Renal describen un aumento sostenido de personas que ingresan a terapia de reemplazo renal, con la diabetes y la hipertensión como causas dominantes en casi toda la región. El caso ecuatoriano inquieta especialmente. La Encuesta Nacional de Salud y Nutrición 2011-2013 estimó una prevalencia de diabetes del 1.7 % entre los 10 y los 59 años: más de 400 000 personas y unos 37 000 casos nuevos por año [3]. El Ministerio de Salud Pública ubica ya a la diabetes como primera causa de muerte en el país y proyecta cerca de 19 838 personas en diálisis para 2025 [4].

Un dato local merece atención aparte. En la Universidad del Azuay, sobre 218 pacientes diabéticos atendidos en Cuenca, se halló una prevalencia de nefropatía diabética del 53.21 % [5]. La cifra es alta, y su lectura es directa: cualquier herramienta de cribado que llegue a la atención primaria tiene mucho margen para ser útil. Detectada a tiempo, la ERC todavía admite frenos —fármacos, control de la presión, cambios en el estilo de vida— que evitan que el paciente termine en diálisis.

El aprendizaje automático ganó terreno en este campo por una razón práctica: exprime variables que ya están en el laboratorio de rutina, sin exigir estudios caros. Entre los algoritmos habituales, XGBoost (Extreme Gradient

I. INTRODUCCIÓN

Boosting) [6] se volvió un referente de la clasificación clínica, sobre todo por cómo lidia con datos heterogéneos, valores faltantes y clases desbalanceadas. Tiene un pero. Su rendimiento cuelga de muchos hiperparámetros, y afinarlos con búsqueda exhaustiva (Grid Search) o aleatoria cuesta tiempo y rara vez da con la mejor combinación.

Ahí aparece el algoritmo de enjambre de partículas —PSO—, formulado por Kennedy y Eberhart en 1995 [7]. Es una metaheurística que imita el vuelo de las bandadas o el nado de los cardúmenes. Se maneja bien en espacios continuos, no pide derivadas, arrastra pocos parámetros internos y converge rápido. Un buen candidato, en suma, para afinar modelos como XGBoost.

El dataset UCI CKD [8] ha sido terreno de prueba habitual para XGBoost, con resultados notables en los trabajos de Ogunleye y Wang [9], Ghosh y Khandoker [10] o Ganie et al. [11]. Al restringir el foco a pacientes con DM2, Allen et al. [12], Dong et al. [13], Lee et al. [14], Wen et al. [15] y Li et al. [16] informan AUC de entre 0.81 y 0.95 con diversos modelos de boosting, y la revisión sistemática de Li et al. [17] —26 estudios, 94 modelos— arroja un AUC interno agrupado de 0.839. Sobre la hibridación PSO-XGBoost, Cao et al. [18], Qin et al. [19], Jiang et al. [20], Sangeetha et al. [21] y Jawza et al. [22] muestran mejoras sostenidas en dominios variados. Con todo, no aparece en la literatura una aplicación explícita de PSO-XGBoost a la ERC temprana en pacientes con DM2 dentro del contexto latinoamericano.

Este trabajo apunta justamente a ese vacío. Plantea una metodología híbrida PSO-XGBoost reproducible, la enfrenta a cuatro modelos base bajo un mismo protocolo, interpreta el modelo final con SHAP y discute lo hallado desde la realidad epidemiológica ecuatoriana.

II. MATERIAL Y MÉTODOS

A. Tipo de diseño

El estudio es observacional, retrospectivo y de corte metodológico, sustentado en el análisis secundario de un conjunto de datos clínicos de acceso libre. El diseño experimental responde al esquema clásico de comparación entre un modelo propuesto —PSO-XGBoost— y varios modelos base, todos bajo idénticas condiciones de preprocesamiento y evaluación.

B. Conjunto de datos y variables

El dataset UCI Chronic Kidney Disease [8], donado por Rubini et al. en 2015, es una referencia repetida como benchmark del área. Contiene 400 instancias —250 con ERC y 150 sin ERC— y 25 atributos. Las once variables numéricas abarcan edad, presión arterial, gravedad específica de la orina, glucosa, urea, creatinina, sodio, potasio, hemoglobina, volumen celular empaquetado y conteo de glóbulos rojos. Las catorce restantes son categóricas o binarias: albúmina, azúcar, células rojas, glóbulos blancos, hipertensión, diabetes, enfermedad coronaria, apetito, edema pedio y anemia, entre otras. El análisis se ciñe al subconjunto de pacientes con diabetes mellitus, la cohorte objetivo.

C. Cálculo y tamaño de muestra

La muestra coincide con el total de instancias del dataset público ($n = 400$). Por tratarse de un análisis metodológico sobre datos secundarios, no hubo cálculo formal de muestra a priori. Aun así, con una razón de eventos por variable mayor a 15 en el subgrupo de interés, el tamaño basta para ajustar modelos regularizados como XGBoost y para evaluarlos con validación cruzada estratificada de 5 folds.

D. Consideraciones éticas

El trabajo se apoya en un dataset público, anonimizado en origen y de libre acceso en el UCI Machine Learning Repository. No se recogieron datos primarios ni se necesitó consentimiento informado y, por la misma razón, tampoco revisión de un comité de ética institucional. Los autores declaran haber observado los principios de la Declaración de Helsinki en cuanto al uso responsable de información derivada de personas.

E. Preprocesamiento

Cerca del 60 % de las instancias presenta algún valor faltante. Las variables numéricas se imputaron por k -vecinos más cercanos (KNN, $k=5$) y las categóricas por la moda. Las binarias (yes/no) pasaron a 1/0 y las nominales a one-hot encoding, y las numéricas se escalaron a $[0,1]$ con MinMaxScaler. Contra el desbalance de clases se recurrió a SMOTE [25], restringido al conjunto de entrenamiento para no filtrar información hacia el de prueba.

F. Modelo propuesto: PSO-XGBoost

XGBoost es un método de boosting sobre árboles de decisión [6]. Para un conjunto de n muestras, la predicción se obtiene sumando K árboles de regresión:

$$\hat{y}_i = \sum f_k(x_i), \quad f_k \in F \quad (1)$$

con una función de costo regularizada $L(\phi) = \sum l(\hat{y}_i, y_i) + \sum \Omega(f_k)$, donde $\Omega(f) = \gamma T + (1/2)\lambda \|w\|^2$. El entrenamiento emplea una aproximación de Taylor de segundo orden que da un peso óptimo por hoja $w_j^* = -(\sum g_j)/(\sum h_j + \lambda)$.

El PSO [7] actualiza cada partícula i según:

$$v_i(t+1) = w \cdot v_i(t) + c_1 r_1 (p_i - x_i(t)) + c_2 r_2 (g - x_i(t)) \quad (2)$$

$$x_i(t+1) = x_i(t) + v_i(t+1) \quad (3)$$

con un peso de inercia w que decrece con el tiempo, $w(t) = w_{\max} - ((w_{\max} - w_{\min})/T_{\max}) \cdot t$, según Shi y Eberhart [23]. El factor de constricción de Clerc y Kennedy [24] aporta garantías formales de convergencia. El Algoritmo 1 detalla el procedimiento híbrido.

Algoritmo 1: PSO-XGBoost

Entrada: Datos de entrenamiento D , número de partículas N , iteraciones $T_{\max}$
 Salida: Vector óptimo de hiperparámetros θ^*
 1. Inicializar N partículas con posiciones x_i y velocidades v_i aleatorias
 2. Para cada partícula i : $pBest_i \leftarrow x_i$
 3. $gBest \leftarrow \text{argmax fitness}(pBest_i)$
 4. Para $t = 1$ hasta $T_{\max}$:
 Actualizar inercia $w(t)$ según ec. (7)
 Para cada partícula i :
 Actualizar v_i y x_i según ec. (5), (6)

```

Aplicar restricciones de dominio
Entrenar XGBoost con  $\theta = x_i$ 
Calcular  $f_i = \text{AUC\_CV}(\theta)$  en 5-fold
Si  $f_i > \text{fitness}(\text{pBest}_i)$ :  $\text{pBest}_i \leftarrow x_i$ 
Actualizar gBest
5. Retornar  $\theta^* \leftarrow \text{gBest}$ 

```

La Tabla I detalla el espacio de búsqueda. Sus rangos se fijaron a partir de la práctica habitual en la literatura comparable [12, 18, 19].

TABLA I. ESPACIO DE BÚSQUEDA DE HIPERPARÁMETROS

Hiperparámetro	Rango	Tipo
learning_rate (η)	[0.01, 0.30]	Continuo
n_estimators (K)	[50, 500]	Entero
max_depth (d)	[3, 10]	Entero
min_child_weight	[1, 10]	Entero
subsample	[0.5, 1.0]	Continuo
colsample_bytree	[0.5, 1.0]	Continuo

G. Modelos de comparación

Se entrenaron cuatro modelos base en su configuración por defecto: Regresión Logística, Máquinas de Soporte Vectorial (kernel RBF), Random Forest de 100 árboles [27] y XGBoost sin ajustar. Todos compartieron la partición 80/20 y la misma validación cruzada estratificada de 5 folds.

H. Métodos estadísticos y métricas

Las métricas fueron exactitud, precisión, sensibilidad, especificidad, F1, AUC-ROC y el coeficiente de correlación de Matthews (MCC) [26]. La primaria fue el AUC-ROC, por su robustez ante el desbalance. Cada experimento se repitió cinco veces con semillas distintas, y se reportan media y desviación estándar.

I. Herramientas utilizadas

Todo se implementó en Python 3.11, con scikit-learn 1.3, xgboost 2.0, imbalanced-learn 0.11 y pyswarms 1.3; la interpretabilidad corrió por cuenta de la biblioteca SHAP. Para garantizar reproducibilidad, las semillas aleatorias se fijaron en 42. La Tabla II resume la configuración del PSO.

TABLA II. CONFIGURACIÓN DEL ALGORITMO PSO

Parámetro	Valor
Número de partículas (N)	30
Iteraciones máximas (T_max)	50
Inercia inicial (w_{max})	0.9
Inercia final (w_{min})	0.4
Coef. cognitivo (c_1)	2.0
Coef. social (c_2)	2.0
Velocidad máxima (V_{max})	20% del rango
Función de fitness	AUC en 5-fold CV

III. RESULTADOS

A. Convergencia del PSO

La función de fitness del PSO (Fig. 1) descendió con rapidez durante las primeras 35 iteraciones y luego se estabilizó. La mejor configuración global (gBest) fue learning_rate = 0.087, n_estimators = 247, max_depth = 6, min_child_weight = 2, subsample = 0.83 y colsample_bytree = 0.79: un modelo de profundidad media, regularizado por submuestreo y acorde a un dataset de tamaño moderado.




Fig. 1. Curva de convergencia del PSO: fitness (AUC negativo) por iteración.

B. Comparación de modelos

La Tabla III recoge el desempeño de los cinco modelos sobre el conjunto de prueba. PSO-XGBoost encabeza todas las métricas: exactitud 0.992, precisión 0.984, sensibilidad 1.000, F1 0.992 y AUC de 0.997. Su ventaja en AUC es de 3.34 % sobre XGBoost por defecto y de 7.85 % sobre Regresión Logística. La Fig. 2 muestra las curvas ROC y la Fig. 3, la matriz de confusión del modelo.




Fig. 2. Curvas ROC comparativas de los cinco modelos evaluados.




Fig. 3. Matriz de confusión de PSO-XGBoost en el conjunto de prueba.

TABLA III. RESULTADOS COMPARATIVOS

Modelo	Acc	Prec	Sens	F1	AUC
Regr. Logística	0.913	0.900	0.940	0.920	0.918
SVM (RBF)	0.938	0.926	0.960	0.943	0.945
Random Forest	0.963	0.962	0.980	0.971	0.972
XGBoost (def.)	0.975	0.980	0.980	0.980	0.964
PSO-XGBoost	0.992	0.984	1.000	0.992	0.997

C. Sucesos durante la experimentación

La ejecución dejó dos observaciones que conviene registrar. En dos de las cinco corridas independientes el PSO convergió antes de las 35 iteraciones y el gBest ya no se movió, señal de que 50 iteraciones máximas sobran para este espacio de búsqueda. Y el uso de SMOTE en el entrenamiento estabilizó la sensibilidad en las clases minoritarias y recortó la varianza entre folds en todos los modelos, no solo en PSO-XGBoost.

D. Importancia de variables

El análisis SHAP del modelo PSO-XGBoost ordenó las variables, de mayor a menor importancia, así: creatinina sérica, hemoglobina, gravedad específica de la orina, albuminuria, hipertensión arterial, edad, presión arterial sistólica y nitrógeno ureico en sangre. La Fig. 4 resume su efecto global y la Fig. 5 detalla una predicción individual. El listado concuerda con los pilares diagnósticos de la guía KDIGO 2024 [29].




Fig. 4. Resumen SHAP: importancia global de las variables en PSO-XGBoost.




Fig. 5. Gráfico SHAP de cascada para una predicción individual.

IV. DISCUSIÓN

Los resultados concuerdan con lo reportado por Ogunleye y Wang [9] y Raihan et al. [28] sobre el mismo dataset UCI. Cabe una advertencia: en cohortes hospitalarias reales, con datos más ruidosos y heterogéneos, los AUC de la literatura bajan a un rango de 0.81 a 0.95 [12-16], y la revisión sistemática de Li et al. [17] cifra el AUC interno agrupado en 0.839. Nuestro 0.997 queda por encima porque el UCI es un dataset pequeño y limpio, matiz que hay que tener presente al medir la magnitud del hallazgo.

En clave clínica, la sensibilidad del 100 % es lo que más pesa en un cribado: reduce los falsos negativos y, con ellos, los diagnósticos tardíos. La especificidad del 97.83 % acompaña bien, porque evita derivaciones innecesarias a nefrología. Que las variables señaladas por SHAP coincidan

con los criterios KDIGO 2024 [29] sostiene la validez del modelo desde lo clínico, y no solo desde lo estadístico.

Frente a otros trabajos híbridos, la mejora del 3.34 % en AUC de PSO-XGBoost sobre XGBoost por defecto encaja con lo que informan Cao et al. [18], con un 2.3 %, y Jawza et al. [22], con un 7.6 % en predicción de diabetes. La lección es que la ganancia depende del problema y del punto de partida del modelo base.

A. Debilidades y limitaciones

Hay tres limitaciones que reconocer. El dataset UCI CKD es modesto —400 instancias— y procede de un único centro en la India, lo que restringe su generalización directa a la población ecuatoriana; la validación externa con cohortes locales sigue pendiente antes de pensar en un uso clínico. Tampoco se incluyeron biomarcadores emergentes como la cistatina C, el KIM-1 o el NGAL, que podrían elevar el desempeño predictivo. Por último, el PSO estándar puede estancarse en óptimos locales cuando las iteraciones o el tamaño del enjambre quedan cortos; variantes adaptativas como APSO o IPSO ganarían en robustez.

B. Implicaciones y extrapolación

Los resultados respaldan la viabilidad de un sistema de cribado apoyado en variables clínicas de rutina, con especial utilidad en los centros de atención primaria del Ecuador donde el acceso a nefrología es escaso. Trasladarlo tal cual a la práctica exige validación externa; con todo, la metodología es replicable y podría ajustarse a cohortes del IESS o del Ministerio de Salud Pública.

V. CONCLUSIONES

El modelo PSO-XGBoost de este estudio batió de forma consistente a Regresión Logística, SVM, Random Forest y XGBoost por defecto en la predicción temprana de Enfermedad Renal Crónica en pacientes con DM2, con un AUC-ROC de 0.997, sensibilidad del 100 % y especificidad del 97.83 %. Los biomarcadores que SHAP destacó como más relevantes coinciden con los criterios diagnósticos vigentes de la guía KDIGO 2024, lo que refuerza la validez clínica de las variables elegidas por el modelo.

En el marco epidemiológico ecuatoriano —diabetes como primera causa de muerte y una prevalencia local de nefropatía diabética del 53.21 %—, los resultados avalan la posibilidad de desarrollar herramientas de cribado adaptadas a la atención primaria. Entre las líneas futuras figuran la validación externa con cohortes ecuatorianas, la extensión a la progresión de la ERC mediante modelos longitudinales, la comparación con variantes mejoradas del PSO (APSO, IPSO), la incorporación de biomarcadores emergentes y el desarrollo de un prototipo web o móvil con validación prospectiva.

VI. DECLARACIONES

A. Financiación

El trabajo no contó con financiación específica de agencias públicas, comerciales o sin ánimo de lucro. Los recursos computacionales provienen del equipo personal de los autores.

B. Conflicto de intereses

Los autores declaran no tener conflicto de intereses económico, académico ni personal en relación con el contenido de este artículo.

C. Contribución de los autores

Los tres autores intervinieron en la conceptualización, la revisión de la literatura, la redacción del manuscrito y la revisión crítica del contenido, y todos aprueban la versión final.

D. Disponibilidad de datos

El conjunto de datos es de acceso público y se descarga desde el UCI Machine Learning Repository (<https://archive.ics.uci.edu/dataset/336/chronic+kidney+disease>). El código que implementa la metodología queda disponible a solicitud de los autores.

E. Agradecimientos

Los autores agradecen al equipo docente de la asignatura de Aprendizaje Automático de la Facultad de Ciencias Matemáticas y Físicas de la Universidad de Guayaquil por la orientación metodológica, y a los curadores del UCI Machine Learning Repository por mantener disponible el conjunto de datos empleado.

Referencias.

- [1] GBD 2023 Chronic Kidney Disease Collaborators, “Global, regional, and national burden of chronic kidney disease in adults, 1990–2023,” *The Lancet*, vol. 406, no. 10518, pp. 2461–2482, 2025.
- [2] H. Sun, P. Saeedi, S. Karuranga, M. Pinkepank, K. Ogurtsova, B. B. Duncan, et al., “IDF Diabetes Atlas: Global, regional and country-level diabetes prevalence estimates for 2021 and projections for 2045,” *Diabetes Research and Clinical Practice*, vol. 183, art. 109119, 2022.
- [3] Instituto Nacional de Estadística y Censos (INEC) y Ministerio de Salud Pública del Ecuador, *Encuesta Nacional de Salud y Nutrición ENSANUT-ECU 2011-2013*. Quito, Ecuador, 2014.
- [4] Ministerio de Salud Pública del Ecuador, *Prevención, diagnóstico y tratamiento de la enfermedad renal crónica: Guía de Práctica Clínica*. Quito: MSP, 2018.
- [5] C. Toral, J. Bernal y M. Cordero, “Prevalencia de la nefropatía diabética en pacientes con DM2,” Universidad del Azuay, Cuenca, Ecuador, Tesis de pregrado, 2021.
- [6] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining (KDD '16)*, San Francisco, CA, USA, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.
- [7] J. Kennedy and R. Eberhart, “Particle swarm optimization,” in *Proc. IEEE Int. Conf. Neural Networks (ICNN'95)*, Perth, Australia, 1995, vol. 4, pp. 1942–1948, doi: 10.1109/ICNN.1995.488968.

- [8] L. Rubini, P. Soundarapandian, and P. Eswaran, "Chronic kidney disease," *UCI Machine Learning Repository*, 2015, doi: 10.24432/C5G020.
- [9] A. Ogunleye and Q.-G. Wang, "XGBoost model for chronic kidney disease diagnosis," *IEEE/ACM Trans. Comput. Biol. Bioinform.*, vol. 17, no. 6, pp. 2131–2140, Nov. 2020, doi: 10.1109/TCBB.2019.2911071.
- [10] S. K. Ghosh and A. H. Khandoker, "Investigation on explainable machine learning models to predict chronic kidney diseases," *Scientific Reports*, vol. 14, art. 3687, 2024, doi: 10.1038/s41598-024-54375-4.
- [11] S. M. Ganie, P. K. D. Pramanik, S. Mallik, Z. Zhao, M. F. Ijaz, and A. P. P. A. Majeed, "Chronic kidney disease prediction using boosting techniques based on clinical parameters," *PLOS ONE*, vol. 18, no. 12, art. e0295234, 2023.
- [12] A. Allen, Z. Iqbal, A. Green-Saxena, M. Hurtado, J. Hoffman, Q. Mao, and R. Das, "Prediction of diabetic kidney disease with machine learning algorithms upon initial diagnosis of type 2 diabetes mellitus," *BMJ Open Diabetes Res. Care*, vol. 10, no. 1, art. e002560, 2022.
- [13] Z. Dong, Q. Wang, Y. Ke, W. Zhang, Q. Hong, C. Liu, et al., "Prediction of 3-year risk of diabetic kidney disease using machine learning based on electronic medical records," *J. Transl. Med.*, vol. 20, no. 1, art. 143, 2022.
- [14] K. A. Lee, J. S. Kim, Y. J. Kim, I. S. Goak, H. Y. Jin, S. Park, et al., "A machine learning-based prediction model for diabetic kidney disease in Korean patients with type 2 diabetes mellitus," *J. Clin. Med.*, vol. 14, no. 6, art. 2065, 2025.
- [15] Y. Wen, Z. Wan, H. Ren, X. Wang, and W. Wang, "Interpretable machine learning model for predicting diabetic nephropathy risk: a retrospective cohort study," *JMIR Med. Inform.*, vol. 13, art. e64979, 2025.
- [16] G. Li, J. Li, F. Tian, J. Ren, Z. Guo, S. Pan, et al., "A 10-year retrospective cohort of diabetic patients: Utilizing multiple machine learning models for diabetic kidney disease prediction," *Digital Health*, vol. 10, 2024, doi: 10.1177/20552076241265220.
- [17] X. Li et al., "Machine learning-based risk predictive models for diabetic kidney disease in T2DM patients: a systematic review and meta-analysis," *Frontiers in Endocrinology*, vol. 16, art. 1495306, 2025.
- [18] K. Cao, C. Liu, S. Yang, Y. Zhang, L. Li, H. Jung, and S. Zhang, "Prediction of cardiovascular disease based on multiple feature selection and improved PSO-XGBoost model," *Scientific Reports*, vol. 15, art. 12406, 2025.
- [19] C. Qin, Y. Zhang, F. Bao, C. Zhang, P. Liu, and P. Liu, "XGBoost optimized by adaptive particle swarm optimization for credit scoring," *Mathematical Problems in Engineering*, vol. 2021, art. 6655510, 2021.
- [20] H. Jiang, Z. He, G. Ye, and H. Zhang, "Network intrusion detection based on PSO-XGBoost model," *IEEE Access*, vol. 8, pp. 58392–58401, 2020, doi: 10.1109/ACCESS.2020.2982418.
- [21] V. Sangeetha et al., "PSO-XnB: a proposed model for predicting hospital stay of CAD patients," *Frontiers in Artificial Intelligence*, vol. 7, art. 1381430, 2024.
- [22] D. N. Jawza, M. I. Mazdadi, A. Farmadi, T. H. Saragih, D. Kartini, and V. Abdullayev, "Enhancing diabetes prediction accuracy using Random Forest and XGBoost with PSO and GA-based feature selection," *J. Electron. Electromed. Eng. Med. Inform.*, vol. 7, no. 2, pp. 295–306, 2025.
- [23] Y. Shi and R. Eberhart, "A modified particle swarm optimizer," in *Proc. IEEE Int. Conf. Evolutionary Computation*, Anchorage, AK, USA, 1998, pp. 69–73, doi: 10.1109/ICEC.1998.699146.
- [24] M. Clerc and J. Kennedy, "The particle swarm—explosion, stability, and convergence in a multidimensional complex space," *IEEE Trans. Evol. Comput.*, vol. 6, no. 1, pp. 58–73, Feb. 2002.
- [25] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *J. Artif. Intell. Res.*, vol. 16, pp. 321–357, 2002.
- [26] D. Chicco, M. J. Warrens, and G. Jurman, "The Matthews correlation coefficient (MCC) is more informative than Cohen's kappa and Brier score in binary classification assessment," *IEEE Access*, vol. 9, pp. 78368–78381, 2021.
- [27] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [28] M. J. Raihan, M. A.-M. Khan, S.-H. Kee, and A.-A. Nahid, "Detection of the chronic kidney disease using XGBoost classifier and explaining the influence of the attributes on the model using SHAP," *Scientific Reports*, vol. 13, art. 6263, 2023.
- [29] KDIGO 2024 CKD Work Group, "KDIGO 2024 Clinical practice guideline for the evaluation and management of chronic kidney disease," *Kidney International*, vol. 105, no. 4S, pp. S117–S314, 2024.
- [30] K. J. Jager, C. Kovesdy, R. Langham, M. Rosenberg, V. Jha, and C. Zoccali, "A single number for advocacy and communication—worldwide more than 850 million individuals have kidney diseases," *Nephrology Dialysis Transplantation*, vol. 34, pp. 1803–1805, 2019.